

MetalCrow: граф знаний с пофразовым провенансом для научно-технического корпуса горно-металлургической отрасли

Константин Ушенин¹, Артём Голубев², Станислав Малашкевич³,
Степан Остарков⁴, Всеволод Каримов⁵

¹AIRI, ²BIOCAD, ³МГУ, ⁴ИОХ РАН, ⁵Сколтех

arqoofficial.github.io/metalcrow-nn

Аннотация

MetalCrow — поисково-аналитическая система над русско- и англоязычным корпусом научно-технических документов горно-металлургической отрасли. Ядро системы: типизированная онтологическая база знаний. LLM-экстрактор со строгой JSON-схемой раскладывает текст по классам (эксперимент, материал, режим, измерение, вывод); факт без дословной цитаты из источника в базу не попадает, это закреплено ограничениями целостности СУБД. Числа хранятся диапазонами с единицей и базой измерения, имена величин и материалов канонизируются, сопоставимость контролирует шестиосевой шлюз. Доступ к знанию дают 13 типизированных инструментов поверх SQL и гибридный ретрив (лексика + вектор, RRF) с гейтом честности. Диалоговый ReAct-агент планирует вызовы инструментов и синтезирует ответ, в котором каждое утверждение ссылается на источник. Качество измеряет сквозной бенчмарк из 107 вопросов с контролями честности: на вопрос вне корпуса система отвечает «данных нет».

1 Введение

Научно-производственный корпус металлургической компании содержит тысячи разнородных документов: статьи, отчёты, доклады, обзоры. Типовой вопрос инженера структурен: *что уже делали по процессу X при режиме Y и какой был эффект на показатель Z*. Классический векторный RAG (Lewis et al., 2020) отвечает на такой вопрос плохо: он возвращает похожие абзацы, а не сопоставимые факты. Числа в них оторваны от шкал, баз измерения и условий процесса, происхождение утверждений непроверяемо, на вопрос вне корпуса модель галлюцинирует.

MetalCrow решает эти проблемы на уровне модели данных. Основные компоненты:

- **онтологическая модель:** десяток типизированных классов и 15 предикатов в PostgreSQL; провенанс с дословной цитатой обязателен на уровне ограничений БД; граф реализован как представление (VIEW) поверх таблиц;
- **конвейер извлечения:** LLM со строгой JSON-схемой, перепривязка цитат нечётким поиском по исходному тексту, послойная канонизация имён величин и материалов;
- **доступ к знанию:** типизированные инструменты поверх SQL (каждое число берётся из базы) и гибридный ретрив с гейтом честности;
- **диалоговый агент:** ReAct-цикл с параллельным вызовом инструментов и обязательной привязкой каждого утверждения к источнику;
- **сквозной бенчмарк:** 107 вопросов, 435 проверяемых чисел, контроли честности.

2 Архитектура системы

Система состоит из микросервисов вокруг общего хранилища знаний в формате OKF (Open Knowledge Format): Markdown с YAML-метаданными, читаемый человеком и совместимый с обычным файловым стеком (git, s3, Obsidian). Входной контур — REST-сервис с очередью парсинга: PDF и DOCX, включая сканы, конвертируются в OKF-markdown (Docling + OCR, Auer et al., 2024). Поверх хранилища работают два взаимозаменяемых ретрив-сервиса (лёгкий GraphRAG, §2.1, и онтологический, §3–5) и онлайн-поиск литературы (§2.2); все они подключены к ReAct-агенту как инструменты (§6). Общая схема на рис. 1. Доступ к моделям централизован через LLM-прокси, вызовы трассируются в Langfuse. Веб-интерфейс объединяет чат, полнотекстовый поиск, вики сущностей и просмотр графа с Cypher-запросами.

Каждое утверждение в ответах несёт метку достоверности: высокая, средняя, противоречие, внешний источник.

2.1 Лёгкий GraphRAG-контур

Лёгкий контур строит граф знаний (Edge et al., 2024) классическим NLP-конвейером и не использует LLM в онлайн-части. Доменный словарь собирается полуавтоматически: NuExtract 3 (NuMind, 2024) извлекает сущности из параграфов корпуса и синтетических примеров, статистическая фильтрация отсеивает шум, кластеризация по E5-эмбедингам (Wang et al., 2022) склеивает синонимы, результат компилируется в entity ruler для spaCy (Honnibal et al., 2020) и увеличивает словарь впятеро. Офлайн-часть выполняет детекцию языка, лемматизацию и извлечение сущностей на двух языках; граф с дедупликацией хранится в Neo4j, векторный индекс в PostgreSQL. В онлайн-части это один инструмент агента с повышением ранга достоверных источников. Контур обрабатывает 600 файлов примерно за 90 минут при незначительной стоимости, но подтверждает факты только на уровне документа. Онтологический контур закрывает этот разрыв провенансом на уровне фразы.

2.2 Онлайн-поиск литературы

Если ответа нет во внутреннем корпусе, агент ищет во внешней литературе: OpenAlex (Priem et al., 2022) для английской, КиберЛенинка для русской. Сразу в контекст попадают только аннотации; полные тексты скачиваются в фоне, и агент отвечает уже по ним. Одним действием пользователь отправляет статью в очередь парсинга, после чего она появляется в общем графе и вики. Внешние данные всегда помечены отдельной меткой достоверности.

3 Онтологическая модель данных

3.1 Эксперимент как хаб

Схема сознательно компактна: десяток типизированных классов (документ, материал, процесс/режим, измерение, вывод, установка, лаборатория, тема) и закрытый словарь из 15 предикатов (uses_material, applies_process, measured_on, derived_from, supports, contradicts и др.). Словарь расширяется только изменением схемы, не в рантайме. Центральный узел — эксперимент: он связывает

материал, режим, оборудование, лабораторию, измерения, выводы и документ (рис. 2). Вопрос «X при Y → эффект на Z» превращается в соединение таблиц вокруг хаба; количество независимых экспериментов служит мерой надёжности ответа. Роль материала (сырьё, продукт, среда, флюс) задаётся квалификатором ребра. Инженерные утверждения без эксперимента, обычные для обзоров и докладов, хранятся в том же классе выводов на уровне документа.

Степень семантики выбрана низкой: OWL-ризонера нет, весь вывод (транзитивность цепочек переделов, агрегация, поиск противоречий) выполняется обычным SQL. Соответствие внешним стандартам (PROV-O (Lebo et al., 2013), PMDco, QUDT) поддерживается таблицами URI-маппинга как экспортный слой.

3.2 Провенанс как ограничение целостности

Каждый факт (измерение, вывод, материал, ребро) несёт провенанс: идентификатор документа, локатор (страница, параграф, таблица, символьный спан), дословный фрагмент исходного текста, имя экстрактора и уверенность. Обязательность закреплена трижды: валидатором контракта данных, CHECK-ограничением на каждой факт-таблице (непустая цитата в prov) и загрузчиком, который отбраковывает записи без цитаты. Таблицы измерений и выводов append-only: правка создаёт новую версию со ссылкой superseded_by, актуальный срез задаётся одним условием WHERE. Любая строка базы проверяется одним переходом к источнику; фронтенд строит из провенанса прямую ссылку на документ в вики.

3.3 Числа и сопоставимость

Значения хранятся структурно: диапазон (min/nominal/max), единица с аффинным приведением к СИ, база измерения (масс.% ≠ ат.%), шкала, условия. Шкалы твёрдости (HV, HRC, HB) не конвертируются: пересчёт нелинеен и зависит от материала. Перед любым сравнением (поиск противоречий, оценка согласованности, карта пробелов) работает иллюз сопоставимости по шести осям: род величины, шкала, база, размерность единицы, состояние обработки, условия измерения. Предмет измерения тоже ось: «извлечение никеля» несопоставимо с «извлечением




Рис. 1: Архитектура. Очередь парсинга наполняет OKF-хранилище; ретрив-сервисы и онлайн-поиск подключены к ReAct-агенту как инструменты; доступ к LLM централизован прокси-шлюзом.




Рис. 2: Эксперимент-хаб. Каждый факт несёт провенанс с дословной цитатой; граф реализован как представление поверх таблиц.

меди». Без шлюза детектор противоречий тонет в шуме; со шлюзом система отвечает «несопоставимо по осям [шкала, процесс]».

4 Извлечение и канонизация

4.1 LLM-извлечение со строгой схемой

Документ в OKF-markdown разбирается на блоки с локаторами и нарезается на чанки по 6000 символов; обрабатываются первые восемь, до ≈ 48 тыс. символов. Экстрактор вызывает LLM (NuExtract 3 с фолбэком на GPT-OSS-120B); ответ жёстко ограничен JSON-схемой, порождённой из контракта онтологии. Промпт требует дословную цитату при каждом измерении, выводе и утверждении и запрещает конвертировать числа.

Координатам, которые могла бы назвать модель, система не доверяет, поэтому цитата заново ищется в исходном тексте (*перепривязка*). Точное вхождение даёт полный локатор; нечёткое совпадение с порогом 85 снижает уверен-

ность; при провале запись уходит в очередь ручной проверки. Загрузка в БД идемпотентна (детерминированные UUID); батчи извлечения сохраняются и перезагружаются без повторных вызовов LLM.

4.2 Канонизация величин и материалов

Сырые имена величин («извлечение никеля», *recovery of Ni*) проходят послойный канонизатор: отбраковка мусора схемы, качественные наблюдения, точные RU/EN-алиасы, паттерны «вид + предмет», доменные синонимы, подсказки по единице; только неразрешённый остаток уходит одним батч-вызовом LLM. Реестр родов величин открыт: неизвестное имя регистрируется черновиком и попадает в очередь ручной проверки. На срезе корпуса канонизатор свёл 171 сырое имя к 48 родам, два случая остались на ручной разбор.

Материалы дедуплицируются по отраслевому словарю синонимов (20 667 сущностей: 15 851 материал, 4 816 процессов) с защитой квалификаторов: «медный», «никелевый» и «медно-никелевый» файнштейн не сливаются никогда, а падежные и орфографические варианты сливаются. Мягкий режим создаёт обратимые ссылки эквивалентности; жёсткое слияние допускается только для морфологических дублей без конфликта состава. Канонизация сократила реестр материалов с 2108 до 1547 сущностей и уплотнила граф *derived_from* (история переделов), где каждое ребро тоже несёт цитату.

5 Инструменты доступа к знанию

Онтологический сервис публикует 13 типизированных инструментов через единый API (/manifest, /invoke):

- **доказательства:** evidence-ответ (значения, согласованность, цитаты); профиль пространства решений (конверт значений, медиана, надёжность точек);
- **аналитика:** карта пробелов; детектор противоречий; сравнение отечественной и зарубежной практики; сравнение технологий; литобзор; покрытие корпуса;
- **навигация:** история переделов (lineage); хронология; поиск экспертов; окрестность узла графа;
- **полнотекст:** гибридный поиск search_passages.

В каждый инструмент зашит параметризованный SQL-запрос, поэтому каждое число в ответе взято из типизированной строки базы; LLM выбирает маршрут и формулирует ответ поверх найденного. Шлюз сопоставимости (§3) работает внутри аналитических инструментов: детектор противоречий пометает только сопоставимые пары измерений из разных документов с расхождением более 0,3 и выводы с противоположным направлением эффекта при одинаковом факторе.

Гибридный поиск покрывает открытые формулировки. Его индекс объединяет типизированные факты и сырые фрагменты полного текста, поэтому находит и то, что экстрактор не типизировал. Лексический канал (IDF-взвешивание редких терминов поверх полнотекстового индекса PostgreSQL) и плотный канал (pgvector, многоязычные эмбединги (Reimers and Gurevych, 2019), размерность 768) сливаются реципрокным ранжированием (Cormack et al., 2009) с весами 1,0 и 0,5 в пользу лексики: семантика дополняет точное совпадение терминов, важное для чисел из таблиц. Пассажи с числами и измерениями получают повышающий коэффициент. Гейт честности: если в корпусе отсутствует не менее половины значимых терминов запроса, инструмент возвращает «в корпусе нет данных» вместо слабых совпадений.

6 Диалоговый агент

Агент реализует цикл ReAct (Yao et al., 2023) (рис. 3). Планировщик получает вопрос, по-




Рис. 3: ReAct-цикл: план, параллельные инструменты, синтез, граундинг каждого утверждения по фактическим наблюдениям.

Таблица 1: Наполнение онтологической базы (полный проход корпуса).

Документов	306
Измерений (со структурными числами)	2 622
Выводов и утверждений	9 605
Канонических материалов (из 2 108 сырых)	1 547
Отраслевой словарь синонимов, сущностей	20 667

следние шесть реплик диалога и накопленные наблюдения, затем выбирает инструменты. Реестр инструментов строится автоматически из /manifest, поэтому новые инструменты подхватываются без правки кода агента. Диспетчер исполняет до четырёх вызовов параллельно; бюджет ограничен тремя раундами планирования и 25 секундами. Синтезатор формирует от одного до четырёх коротких утверждений со ссылками на конкретные наблюдения. Утверждение проходит граундинг, только если указанные в нём источники действительно есть среди наблюдений; иначе оно получает низкую достоверность и остаётся без атрибуции. При пустом ретриве агент делает резервный широкий поиск и, если пусто и там, честно отвечает «в корпусе нет данных». При сбое LLM запрос обслуживает детерминированный маршрут (онтология, затем граф знаний), так что чат работает и без агента.

7 Оценка

Бенчмарк ходит по тому же публичному чат-API, что и фронтенд, и измеряет конвейер целиком: маршрутизацию, ретрив и синтез. Датасет: 107 вопросов в 17 категориях (обессоливание, электроэкстракция, флотация, хлори-



Рис. 4: Цикл тюнинга: каждый прогон бенчмарка возвращает отчёт с разрезами по категориям, метрикам и латентности.

рование, выщелачивание, аффинаж, геомеханика и др.); 103 отвечаемых и 4 контроля честности; 6 вопросов на английском; 14 патентных проверок; 435 ожидаемых числовых значений. Скоринг детерминированный: ключевые факты 0,30, точность чисел 0,20, провенанс 0,30, маршрутизация 0,10, латентность 0,10; для неотвечаемых вопросов балл равен честности.

Бенчмарк замкнут в цикл разработки (рис. 4); в этом цикле перебирались гиперпараметры ретривера, схема онтологии и поведение агента. Пустая система набирает 0,18: маршрутизация и честность исправны, данных нет. Полный корпус с детерминированным маршрутизатором интенгов даёт $\approx 0,67$ при медианной задержке ≈ 2 с и ссылке на источник в 90 % ответов. Агентный контур даёт $\approx 0,60$ при ≈ 19 с под конкурентной нагрузкой: медленнее, зато синтез связнее и атрибуция строже. Контроли честности агент проходит с оценкой 1,0. Слабейшая метрика (точность чисел из таблиц, $\approx 0,34$) указывает на главный резерв качества.

8 Заключение

Компактная онтология в реляционной БД, обязательный пофразовый провенанс, типизированные инструменты и агент с граундингом собираются в работающую систему инженерными средствами, без тяжёлой семантической машинерии. В отличие от классического векторного RAG такая система возвращает проверяемые числа, сопоставимые факты и честное «данных нет».

Ограничения

- Типизируются первые ≈ 48 тыс. символов документа; длинные отчёты покрываются частично. Индекс сырых фрагментов компенсирует это для ретривера, но не для структурированных запросов.
- Точность извлечения чисел из таблиц ($\approx 0,34$) остаётся главным узким местом; известны единичные ошибки канонизации

(температура, попавшая в род «степень извлечения»).

- Типизированные инструменты покрывают запрограммированные сценарии; вопросы за их пределами обслуживает только гибридный ретрив.
- Агентный контур платит латентностью за последовательные вызовы LLM; онтологическая экстракция требует модели уровня GPT-OSS-120B и полного прохода по корпусу.
- Словарь GraphRAG-контур нужно обновлять под новые корпуса.

References

Christoph Auer, Maksym Lysak, Ahmed Nassar, Michele Dolfi, Nikolaos Livathinos, Panos Vagenas, Cesar Berrospi Ramis, Matteo Omenetti, Fabian Lindlbauer, Kasper Dinkla, et al. 2024. Docling technical report. *arXiv preprint arXiv:2408.09869*.

Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. 2009. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759.

Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. 2024. From local to global: A graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*.

Matthew Honnibal, Ines Montani, Sofie Van Landeghem, and Adriane Boyd. 2020. spaCy: Industrial-strength natural language processing in Python. <https://spacy.io>.

Timothy Lebo, Satya Sahoo, and Deborah McGuinness. 2013. PROV-O: The PROV ontology. W3C recommendation. <https://www.w3.org/TR/prov-o/>.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474.

NuMind. 2024. NuExtract: A foundation model for structured extraction. <https://numind.ai/blog/nuextract-a-foundation-model-for-structured-extraction>.

Jason Priem, Heather Piwowar, and Richard Orr. 2022. OpenAlex: A fully-open index of scholarly works,

authors, venues, institutions, and concepts. *arXiv preprint arXiv:2205.01833*.

Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992.

Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. 2022. Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*.

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. 2023. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR)*.